UNIVERSIDAD EAFIT
VIGILADA | MINEDUCACIÓN

Escuela de
Ciencias Aplicadas
e Ingeniería

Artificial Intelligence

Lecture 06 – Trees & Ensambles; mini Kaggle Context

Contenido

1. Introducción
2. Decision Trees
3. Bootstrap aggregating
4. Boosting
5. Ejemplos de aplicación
6. Kaggle

Introducción

Introducción

UNIVERSIDAD EAFIT
Escuela de Ciencias Aplicadas e Ingeniería

Los modelos simples son eficientes y de rápido entrenamiento, pero pueden llegar a tener poco poder explicativo sobre datos observados (subajuste)

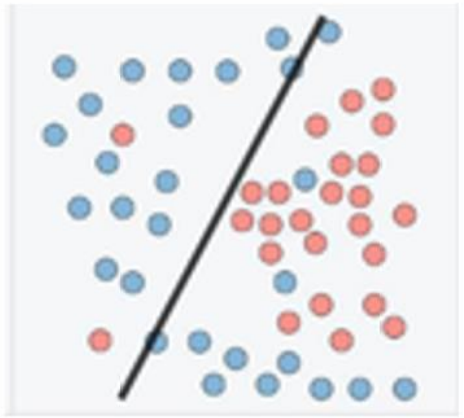

Por otro lado, los modelos muy complejos tienen mucho poder explicativo sobre un conjunto de entrenamiento pero poca habilidad predictiva para datos no observados (sobreajuste).

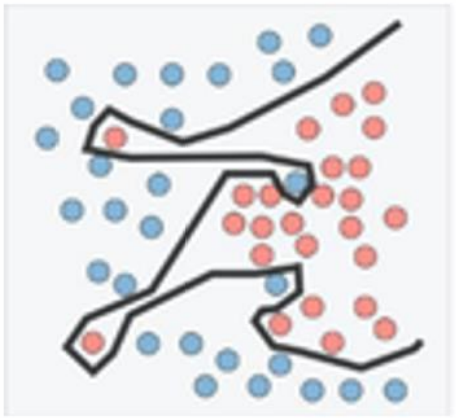

Introducción

Además, los datos en ocasiones tienen una estructura compleja y, específicamente en problemas de clasificación, pueden presentarse clases no balanceadas.

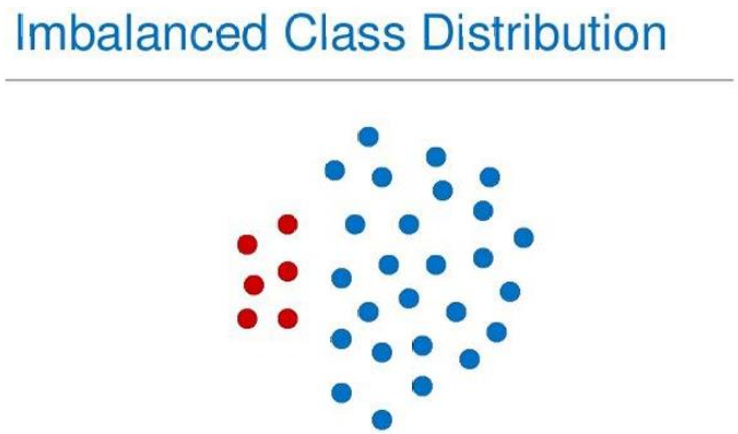

Ejemplos:

- Diagnósticos médicos
- Detección de fraude
- Mantenimiento predictivo
- Seguridad informática
- Detección de Spam

¿Cual otra se te ocurre?

Introducción

Los ensambles combinan varios modelos de Machine Learning para producir una única predicción y pueden presentar mejor desempeño que los modelos individual

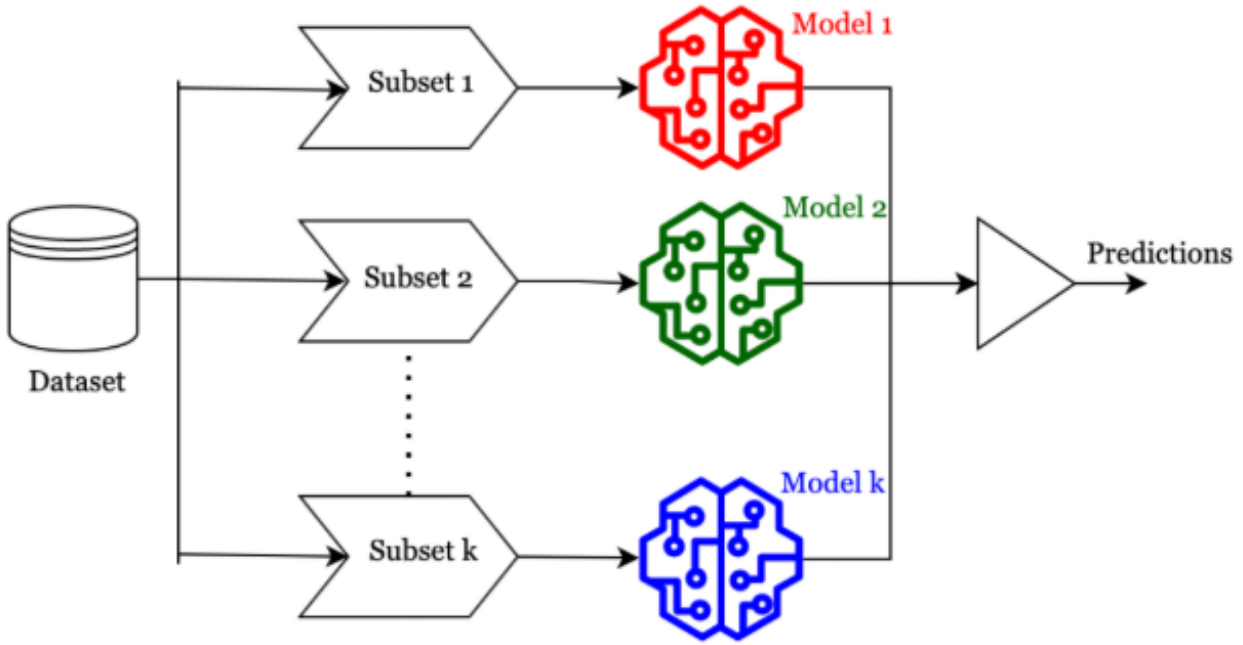

Introducción

La clasificación de los modelos de ensamble se puede abordar desde tres perspectivas:

- Por el tipo de problema que procuran resolver: **subajuste o sobreajuste.**
- Por la manera en la que se entrena el ensamble: **paralelos o secuenciales.**
- Por la variedad de modelos en el ensamble: **homogéneos o heterogéneos.**

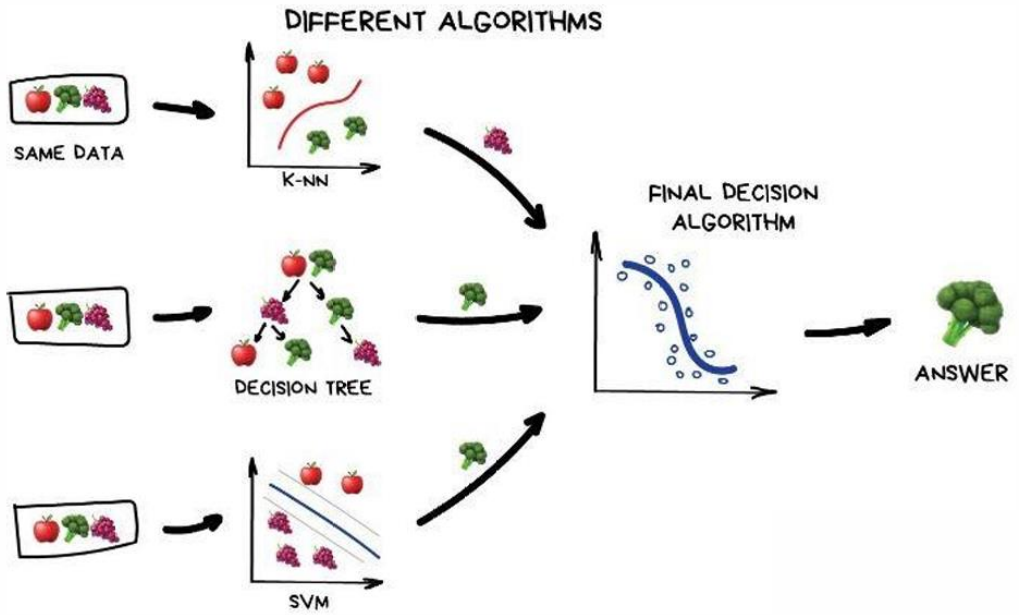

"Different ensemble strategies vary on how exactly the base classifiers are trained and how the combination of predictions is achieved."

Introducción

Empezar con **Decision Trees (Árboles de Decisión)** antes de aprender Ensembles (como Random Forest, Gradient Boosting o XGBoost) es una excelente idea por varias razones fundamentales:

- Los métodos de ensamble más populares (**Bagging** y **Boosting**) se construyen combinando múltiples árboles de decisión.
- Entender cómo funciona un árbol individual te permite:Comprender cómo los ensembles **reducen el overfitting**
- Entender conceptos clave como impureza (Gini/Entropía) que también aplican en ensembles.
- Permiten ver las reglas de decisión en forma de if-else.
- Ayudan a entender cómo se dividen los datos en nodos (útil para debuggear ensembles).

DECISION TREES-ÁRBOLES DE DECISION

DECISION TREES

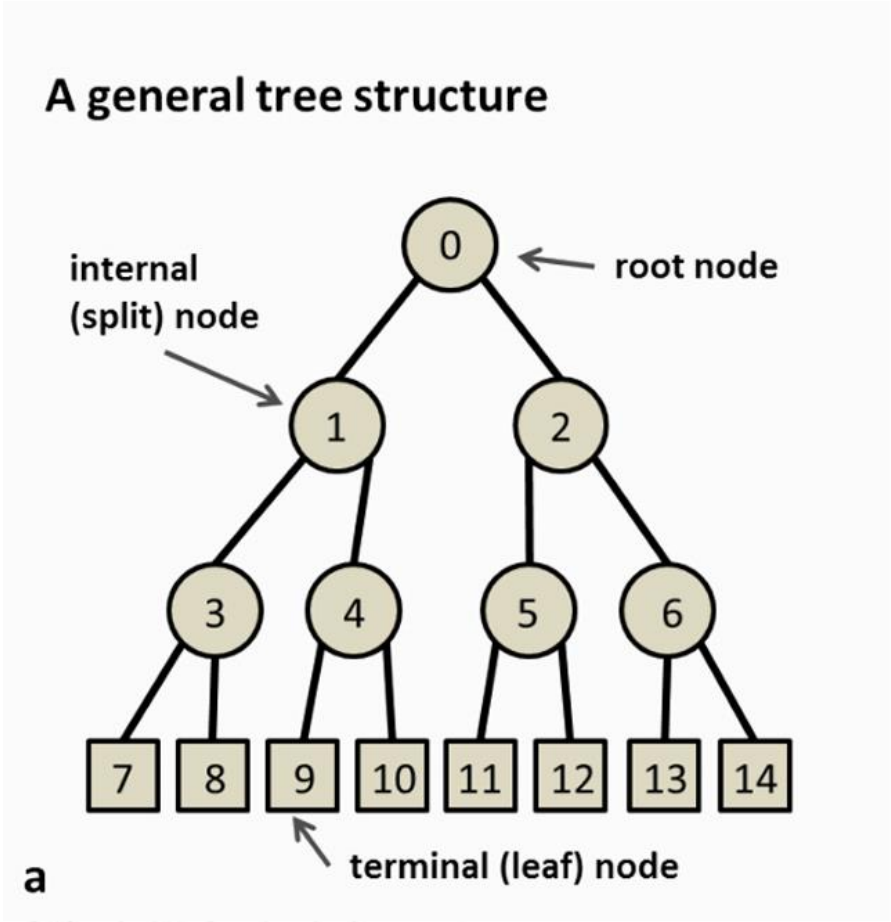

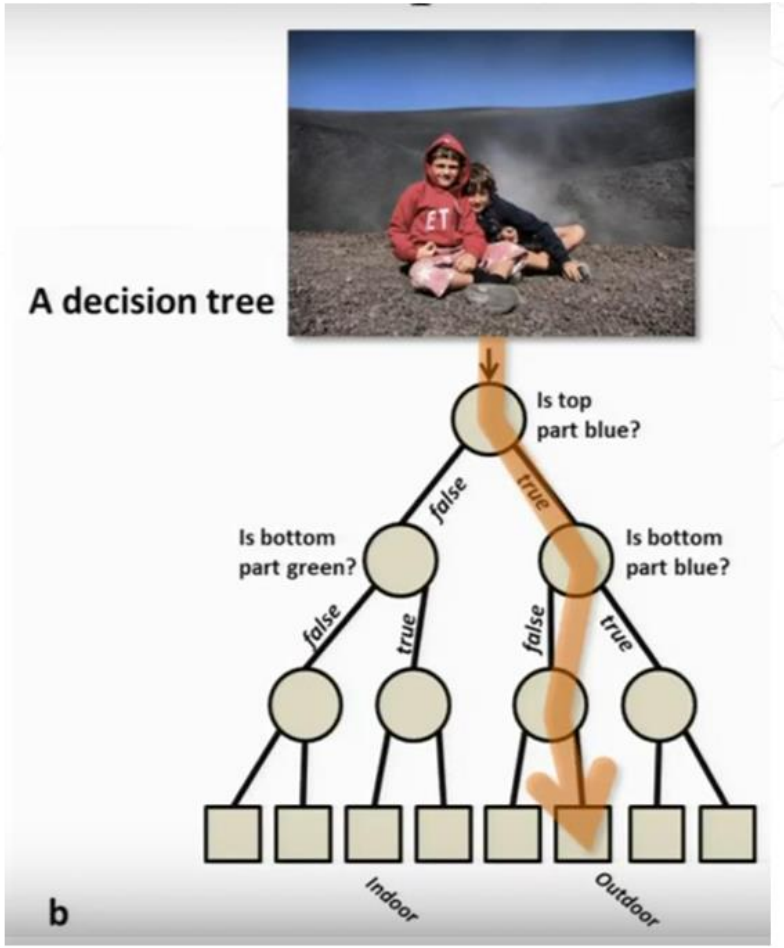

DECISION TREES

UNIVERSIDAD EAFIT

Escuela de Ciencias Aplicadas e Ingeniería

Como funciona?

Ejemplo en un problema biclase

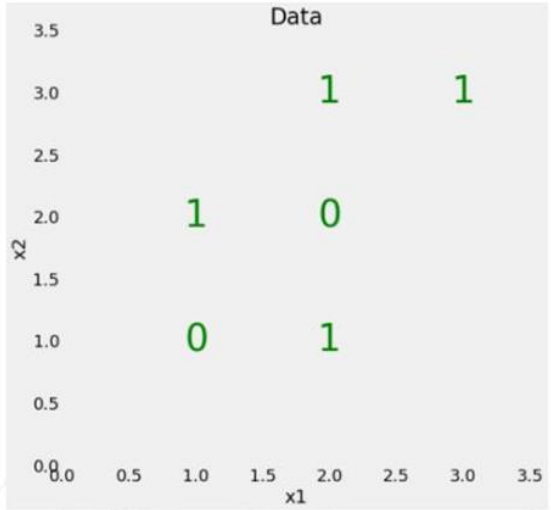

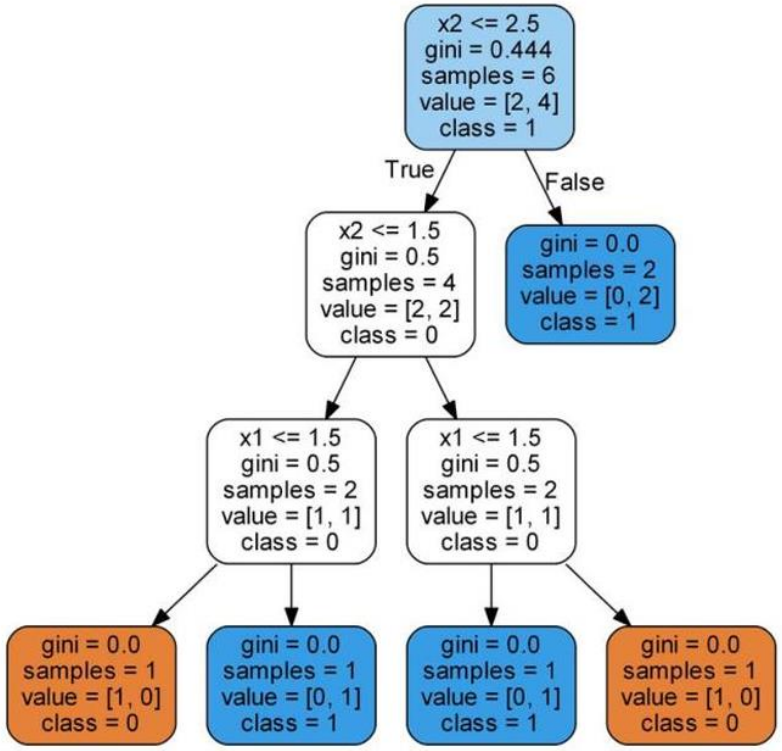

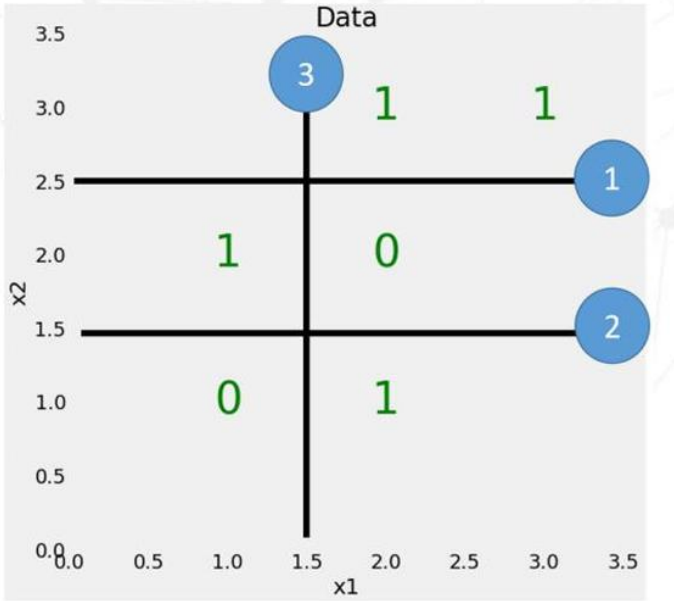

DECISION TREES

UNIVERSIDAD EAFIT
Escuela de Ciencias Aplicadas e Ingeniería

Como funciona?

Ejemplo en un problema multiclase

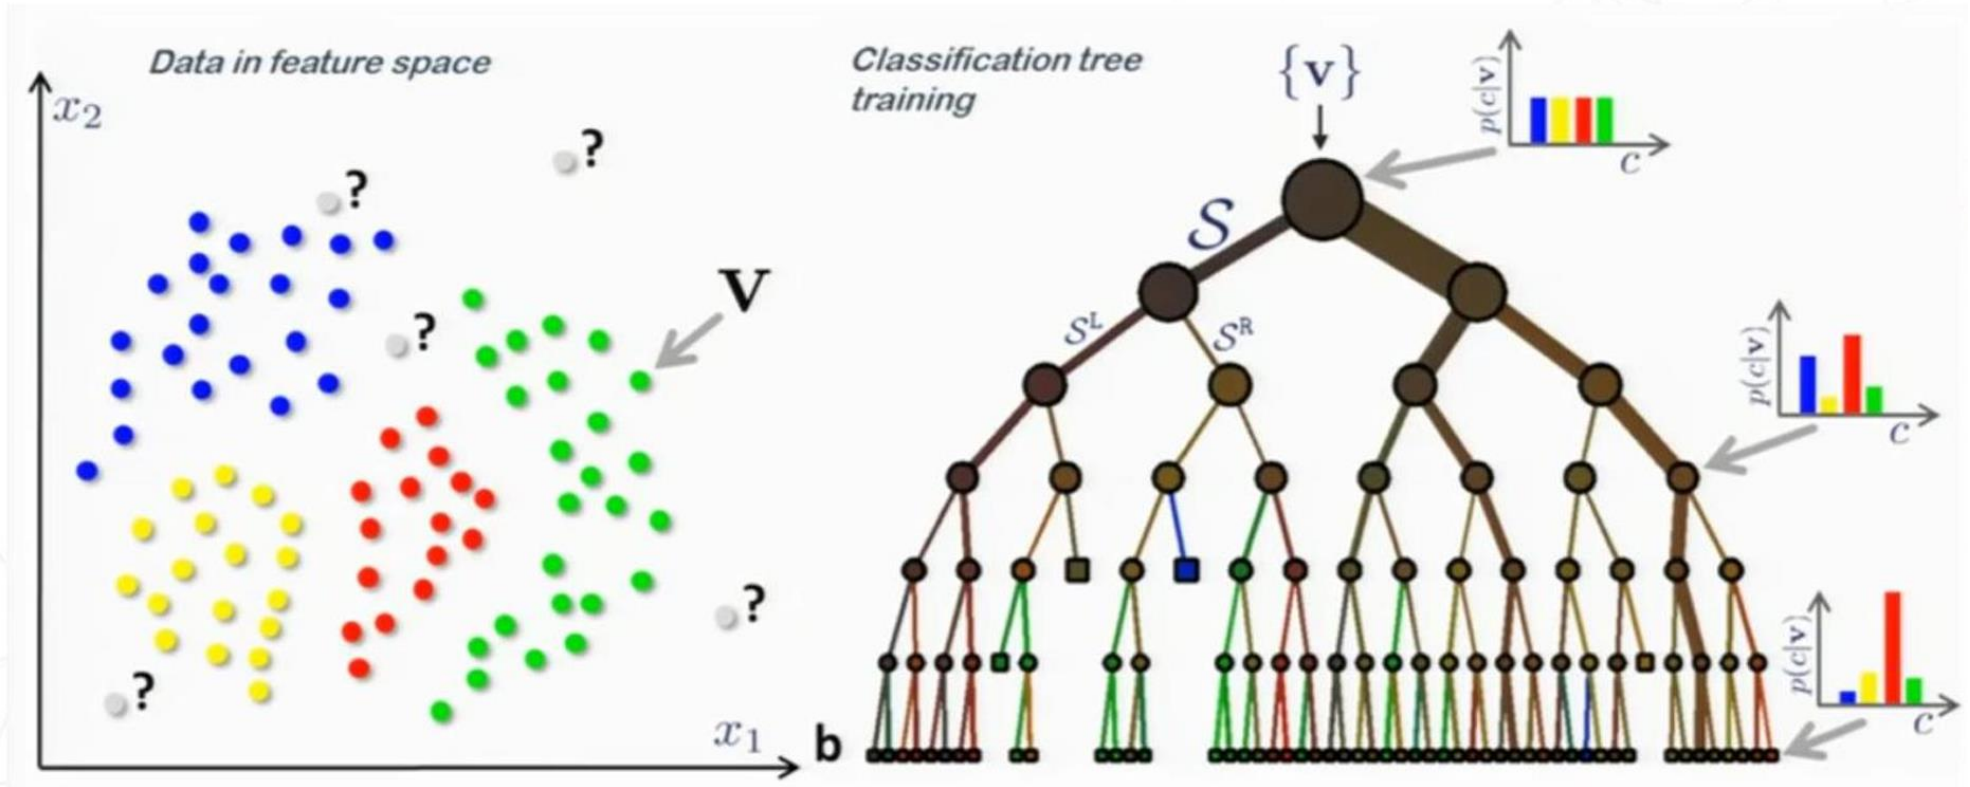

DECISION TREES

UNIVERSIDAD EAFIT

Escuela de Ciencias Aplicadas e Ingeniería

Como tomar las mejores preguntas para generar la división de datos?

Example	Attributes										Target
	Alt	*Bar*	*Fri*	*Hun*	*Pat*	*Price*	*Rain*	*Res*	*Type*	*Est*	*WillWait*
X_1	T	F	F	T	Some	$$$	F	T	French	0–10	T
X_2	T	F	F	T	Full	$	F	F	Thai	30–60	F
X_3	F	T	F	F	Some	$	F	F	Burger	0–10	T
X_4	T	F	T	T	Full	$	F	F	Thai	10–30	T
X_5	T	F	T	F	Full	$$$	F	T	French	>60	F
X_6	F	T	F	T	Some	$$	T	T	Italian	0–10	T
X_7	F	T	F	F	None	$	T	F	Burger	0–10	F
X_8	F	F	F	T	Some	$$	T	T	Thai	0–10	T
X_9	F	T	T	F	Full	$	T	F	Burger	>60	F
X_{10}	T	T	T	T	Full	$$$	F	T	Italian	10–30	F
X_{11}	F	F	F	F	None	$	F	F	Thai	0–10	F
X_{12}	T	T	T	T	Full	$	F	F	Burger	30–60	T

¿Para ti, cual pregunta es mejor?

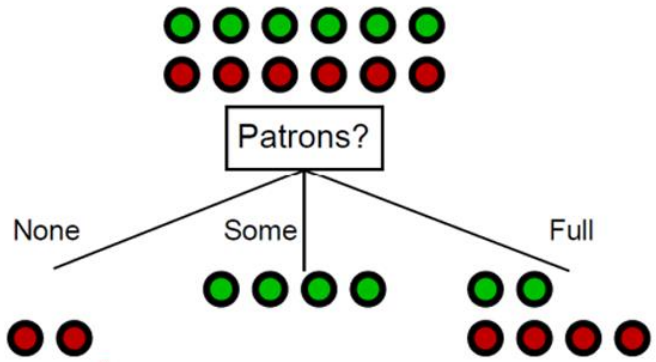

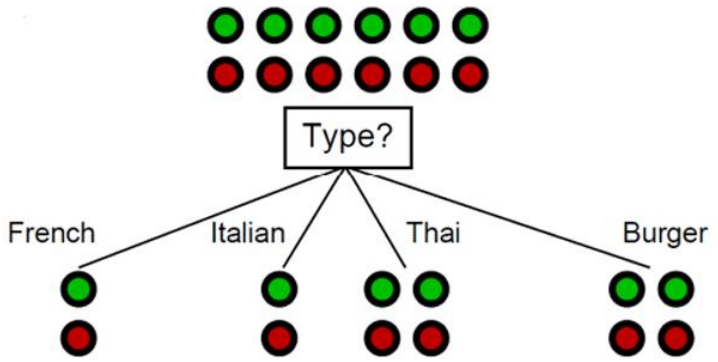

DECISION TREES

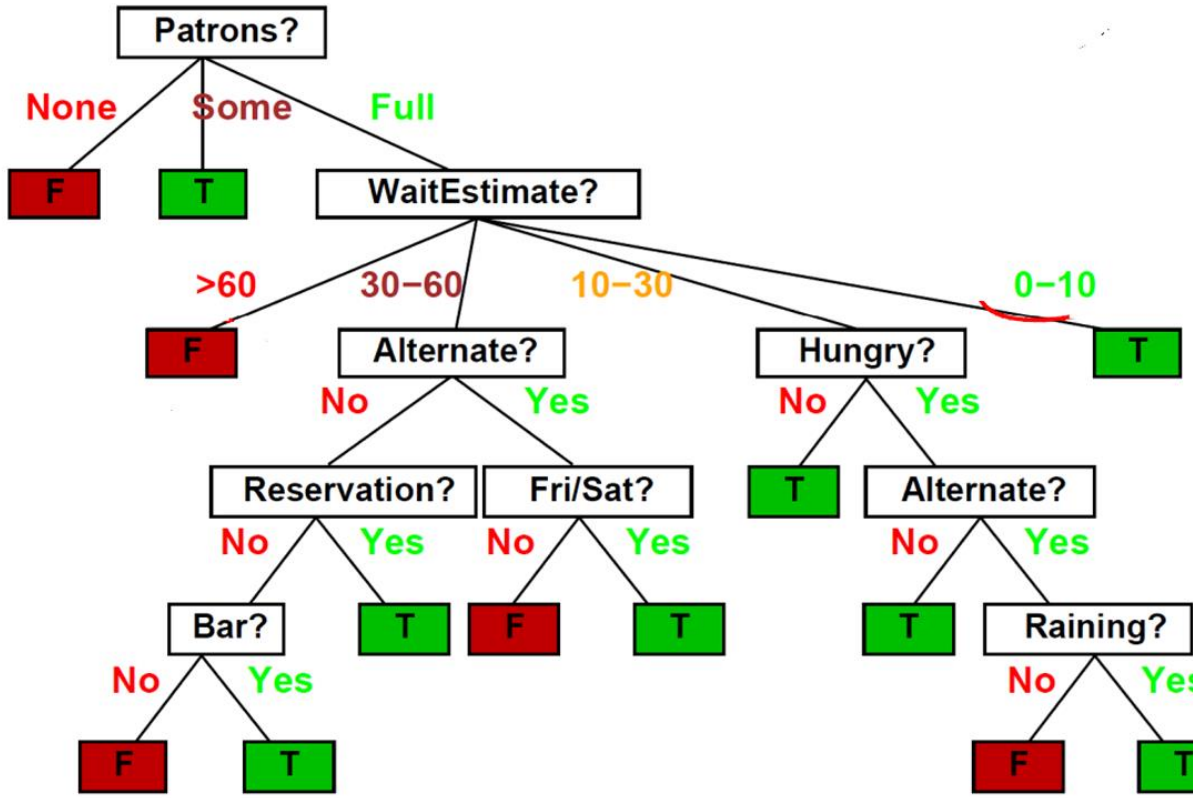

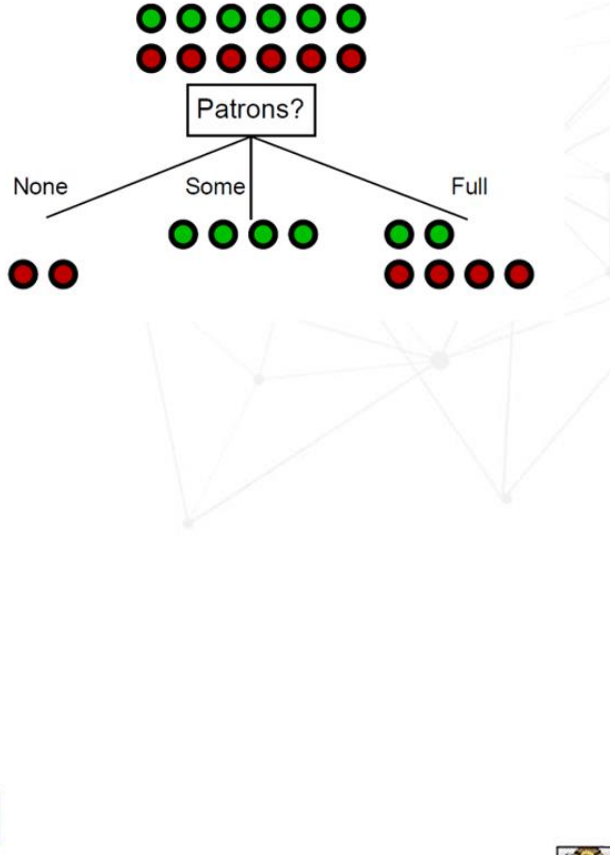

DECISION TREES

UNIVERSIDAD EAFIT
Escuela de Ciencias Aplicadas e Ingeniería

Como tomar las mejores preguntas para generar la división de datos?

ENTROPÍA

$$H(\pi) = -\sum_{\forall \pi} \pi \log_2(\pi)$$

Para un conjunto de entrenamiento con p ejemplos positivos y n ejemplos negativos, tenemos:

$$H(\pi_p, \pi_n) = -\pi_p \log_2 \pi_p - \pi_n \log_2 \pi_n$$

$$\pi_p = \frac{p}{p+n} \qquad \pi_n = \frac{n}{p+n}$$

DECISION TREES

UNIVERSIDAD EAFIT
Escuela de Ciencias Aplicadas e Ingeniería

Como tomar las mejores preguntas para generar la división de datos?

Una variable A, con K valores diferentes, divide el conjunto de entrenamiento E en subconjuntos E1, …, Ek La Expected Entropy (EH) del atributo A (con ramas i=1,2,...,K) es

$$EH(A) = \sum_{i=1}^{K} \frac{p_i + n_i}{p+n} H(\pi_{p_i}, \pi_{n_i})$$

Podemos seleccionar una pregunta que minimice EH(A)

La Information Gain del atributo A es:

$$I(A) = H(\pi_p, \pi_n) - EH(A)$$

Ó podemos seleccionar una pregunta que maximice I(A)

DECISION TREES

Class Example

ENSAMBLES: Bootstrap Aggregating

Bootstrap Aggregating

UNIVERSIDAD EAFIT | Escuela de Ciencias Aplicadas e Ingeniería

Bagging (bootstrap aggregating) es uno de los métodos más simples de ensamble. La idea es tomar varios clasificadores simples y entrenar cada uno con un subconjunto de los datos.

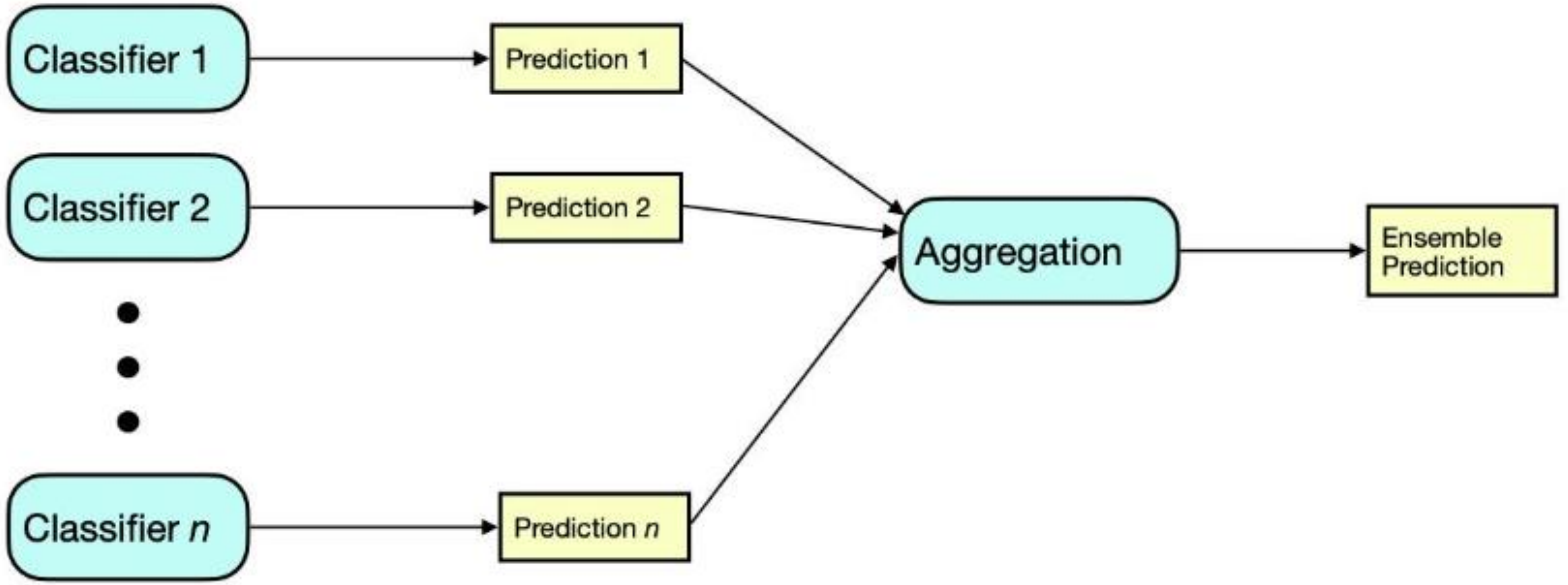

Bootstrap Aggregating

La **predicción** será:

- El promedio de las predicciones de todos los clasificadores simples en el caso de un problema de **regresión.**
- La clase con el mayor número de votos entre todos los clasificadores en el caso de una **clasificación**

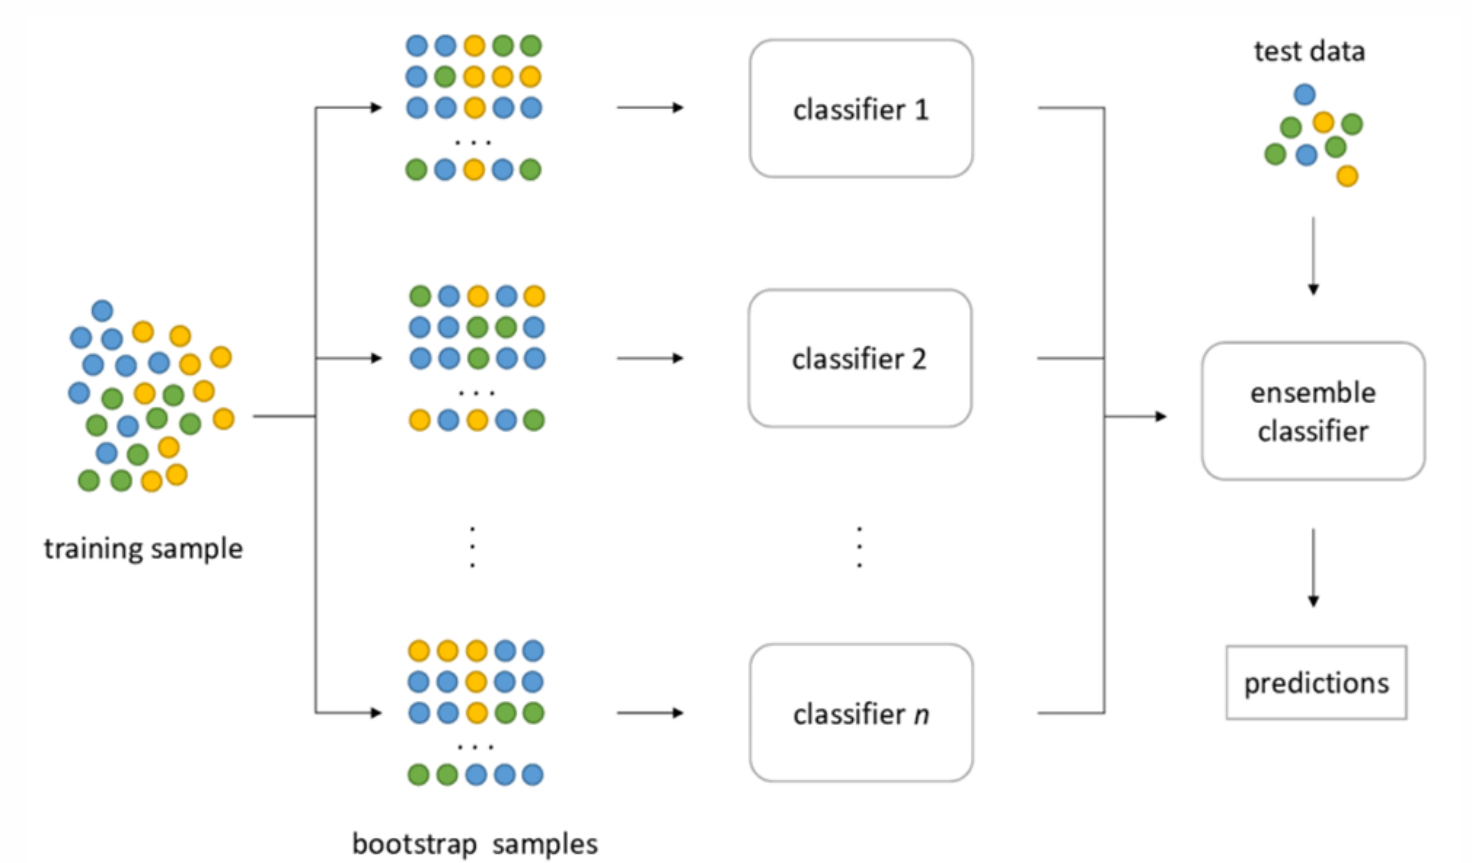

Bootstrap Aggregating

Un ensamble basado en bagging crea los subconjuntos de datos para cada clasificador usando un método conocido como bootstrapping. De manera que el algoritmo se puede resumir en los siguientes pasos:

1. **Para cada uno de los modelos simples:**

a. Cree un subconjunto de entrenamiento usando una muestra del conjunto de entrenamiento (tomada aleatoriamente con reemplazo). Puede ser un porcentaje definido.

b. Entrene el modelo con el subconjunto de datos muestreado.

2. **Para realizar inferencia:**

Promedie el resultado de todos los modelos si es **regression.**
Haga votación de todos los modelos si es **clasificación** (escoja la moda)

Bootstrap Aggregating

UNIVERSIDAD EAFIT
Escuela de Ciencias Aplicadas e Ingeniería

Características:

1. Trata de resolver problemas de sobreajuste.
2. En un ensamble paralelo, es decir que cada modelo es entrenado independiente del otro.
3. Suele ser homogéneo, es decir que se entrena el mismo tipo de clasificadores simples, aunque no hay una razón estricta para no entrenar diferentes.
4. Un ensamble de Árboles de Decisión usualmente se llama **Random Forest.**
5. En bagging también se puede hacer submuestreo de las variables de entrada; así lo hace Random Forest.
6. No funcionan bien con modelos lineales

ENSAMBLES: Boosting

Boosting

UNIVERSIDAD EAFIT | Escuela de Ciencias Aplicadas e Ingeniería

Boosting engloba a una familia de algoritmos cuya idea general es tomar modelos sencillos (por lo general árboles de decisión) y mejorar sus predicciones de manera secuencial.

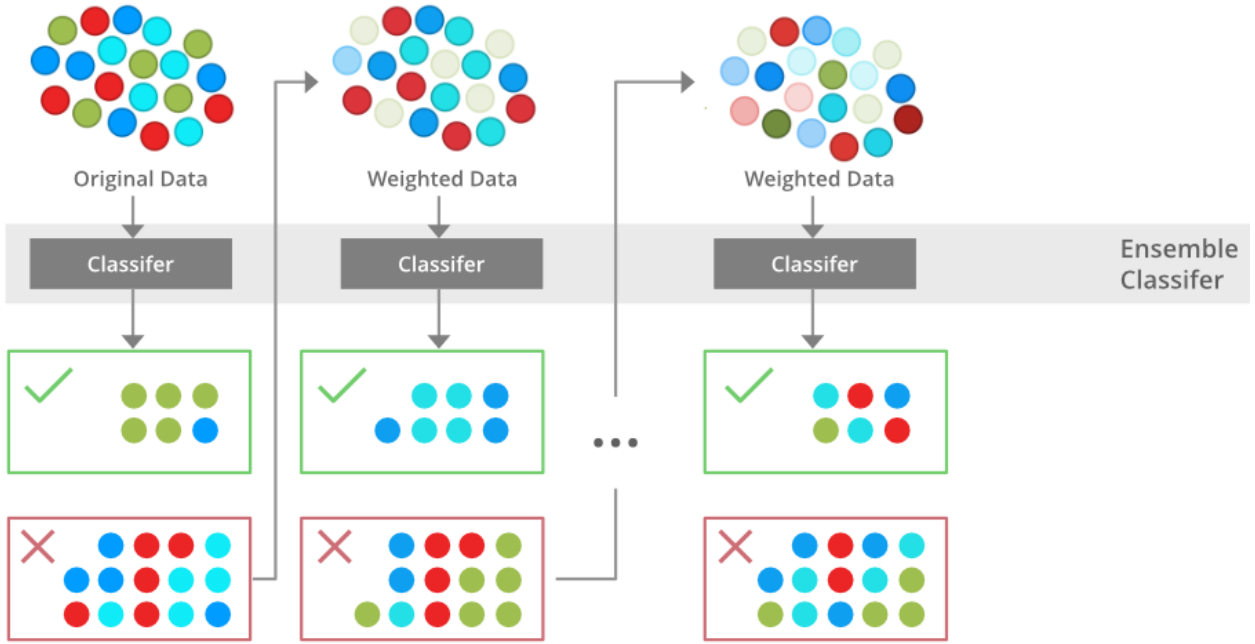

Para mejorar esas predicciones el algoritmo entrena cada modelo secuencialmente con todos los datos y, para cada nuevo modelo, se le da más peso a los datos que no fueron bien clasificados o cuyo error en regresión sea más alto.

Boosting

En lugar de darle más peso directamente a los datos con el mayor error, el gradient boosting entrena el siguiente modelo para que minimice el residual (la diferencia entre las etiquetas y las predicciones del ensamble actual) o para que se ajuste al gradiente de la pérdida

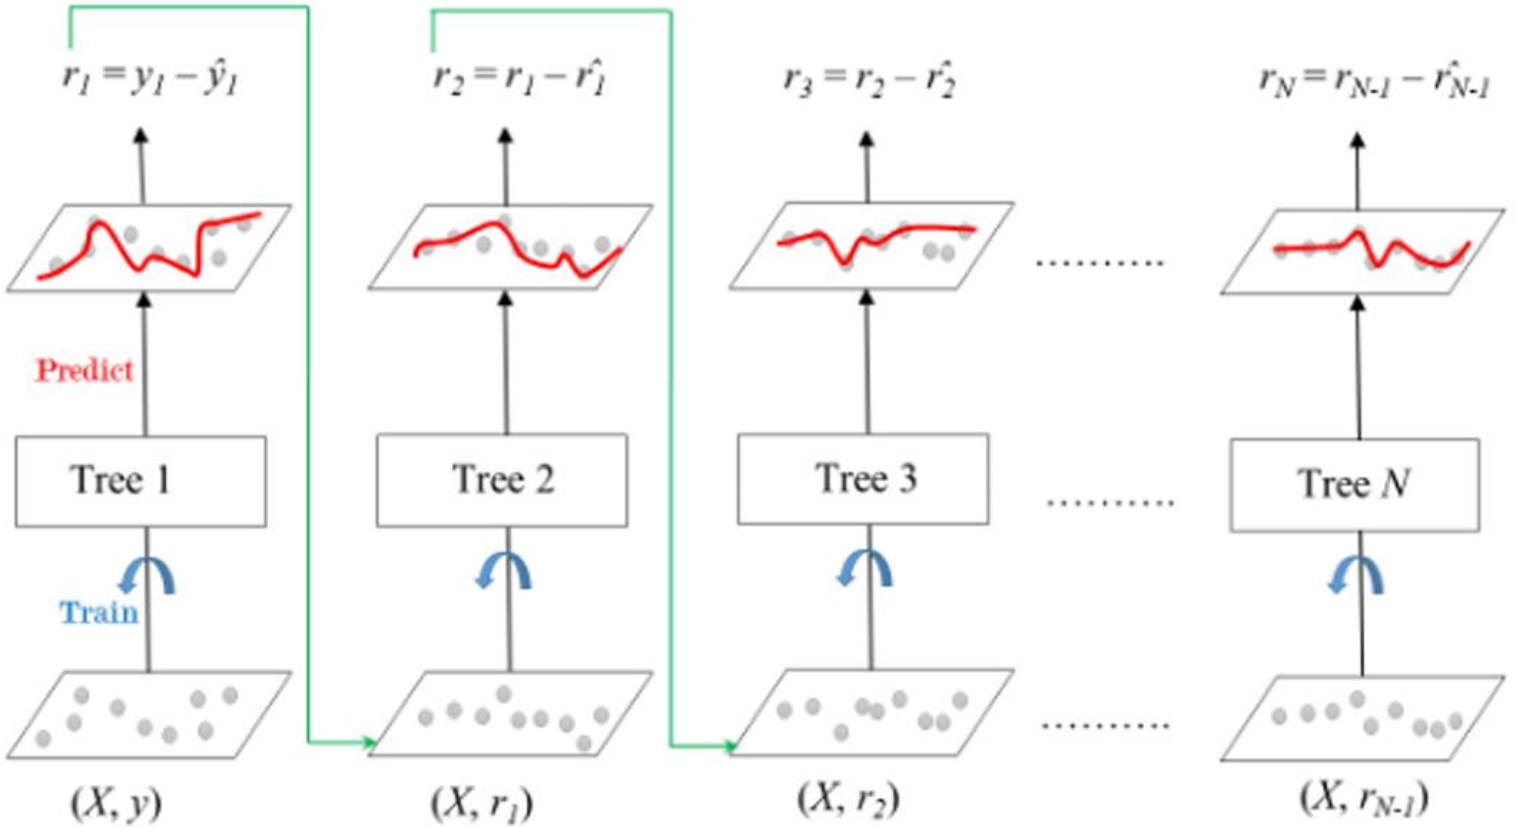

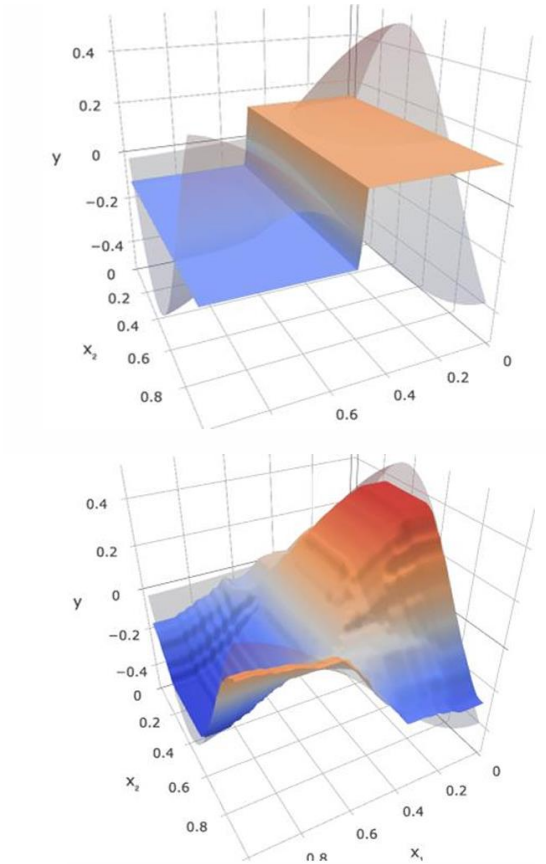

ENSAMBLES

Class Example and Exercise

KAGGLE: Mini-context

KAGGLE: Mini-context

UNIVERSIDAD EAFIT
Escuela de Ciencias Aplicadas e Ingeniería

Qué es Kaggle?

Kaggle es una plataforma en línea especializada en ciencia de datos y aprendizaje automático (machine learning), donde usuarios de todos los niveles pueden colaborar, competir y aprender.

1. Acceder a datasets públicos
2. Participar en competencias de ML
3. Explorar notebooks (kernels) de otros usuarios
4. Aprender con cursos y tutoriales
5. Desarrollar y compartir proyectos propios
6. Experimentar con herramientas en la nube (sin instalar nada)
7. Obtener feedback de la comunidad

kaggle

KAGGLE: Mini-context

UNIVERSIDAD EAFIT | Escuela de Ciencias Aplicadas e Ingeniería

kaggle

☆ **Featured Competitions** Hotness

ARC Prize 2025
Create an AI capable of novel reasoning
Featured · Code Competition
851 Teams
$1,000,000 3 months to go

Red-Teaming Challenge - OpenAI gpt-oss-20b
Find any flaws and vulnerabilities in gpt-...
Featured · Hackathon
5011 Entrants
$500,000 9 days to go

Make Data Count - Finding Data References
Identify scientific data use in papers an...
Research · Code Competition
1067 Teams
$100,000 23 days to go

Jigsaw - Agile Community Rules Classification
Using AI models to help moderators uph...
Featured · Code Competition
900 Teams
$100,000 2 months to go

MITSUI&CO. Commodity Prediction Challenge
Develop a robust model for accurate an...
Featured · Code Competition
592 Teams
$100,000 2 months to go

NeurIPS 2025 - Google Code Golf Championship
Implement a variety of programs using t...
Research
412 Teams
$100,000 2 months to go

BigQuery AI - Building the Future of Data
Build AI solutions with BigQuery
Featured · Hackathon
2526 Entrants
$100,000 A month to go

MAP - Charting Student Math Misunderstandings
Predict the affinity between misconcepti...
Featured · Code Competition
915 Teams
$55,000 2 months to go

Referencias

https://www.geeksforgeeks.org/machine-learning/boosting-in-machine-learning-boosting-and-adaboost/

https://www.kaggle.com/

https://towardsdatascience.com/ensembles-in-machine-learning-9128215629d1/

Russell, S., & Norvig, P. (2020). *Artificial intelligence: A modern approach* (4th ed.). Pearson.